Обработка данных | техническая передача

Kolosok / задача BMW - инструкция для команды - 11 октября 2026 года

Что делает моя часть проекта

Этот конвейер превращает таблицы с отзывами в проверяемые кандидаты тем, точную статистику, английские AI-описания со ссылками на цитаты, удобный локальный отчёт и версионируемую базу SQLite. Он также загружает продажи, исследования клиентов и PDF со списками опций. Исходные файлы и ссылки на строки/ячейки остаются доступными для проверки и дальнейшей интеграции в основной продукт.

Текущее состояние	Проверенное значение
Отзывы F70	4 076 исходных строк; 2 128 уникальных ID отзывов
Анализ F70	460 тем; 7 596 вхождений фрагментов; статус complete
Назначения F70	6 906 пар «отзыв - тема»; 2 115 отзывов попали хотя бы в одну тему
Другие отзывы	G60: 4 000 уникальных отзывов; G70: 4 000; анализ ожидается
Дополнительные данные	36 записей продаж; 1 833 показателя исследований; 78 страниц PDF
База	8 исходных файлов, 1 связанный анализ F70, 54 пройденных Python-теста

Это состояние локальной рабочей копии. Изменения ещё не закоммичены и не отправлены: в текущей задаче недоступен обязательный для репозитория Entire-checkpoint.

Схема работы

Исходный XLSX -> feedback_topics.py -> JSON первого этапа -> summarize_topics.py -> итоговый JSON -> export_topics.py -> локальный HTML, Markdown, JSONL и подробности тем. Параллельно data_library.py загружает XLSX/PDF в SQLite и привязывает оба проверенных JSON к точной версии исходной таблицы. Это четыре отдельные операции. Загрузка новой таблицы сама не запускает AI и не обновляет старый HTML-отчёт.

1. Входные данные, идентичность и сохранность источника

Для анализа отзывов нужны столбцы ID и Customer Feedback; по умолчанию берётся первый лист. Параметры --sheet, --id-column и --text-column позволяют выбрать другую структуру. Country, Engine Type, Derivate (e-code), Feedback Type и исходные категории VFC сохраняются как метаданные. При создании тем используется только Customer Feedback, поэтому старые категории не навязывают новые темы. Токенизация и правила тональности рассчитаны на английский текст; автоматического перевода нет.

Строки с одинаковым ID и одинаковым текстом объединяются в один отзыв. Сохраняются все номера строк Excel и различающиеся значения метаданных. Если одному ID соответствуют разные тексты, первый этап завершается ошибкой. Один отзыв может описывать несколько аспектов и поэтому позднее попасть в несколько тем. Для формул читаются сохранённые значения Excel; формулы не пересчитываются.

В базе ключ набора данных по умолчанию равен имени файла без расширения в нижнем регистре; его можно задать через --dataset. При обновлении таблицы нужно повторно использовать тот же ключ. Новые байты дают неизменяемую полную версию таблицы; тот же SHA-256, ключ и версия импортёра не создают дубль. Повторная загрузка старой версии не делает её актуальной. Ошибка импорта откатывает транзакцию файла. Представления current_* выбирают наибольший номер успешно загруженной версии каждого набора.

Источник	Что сохраняет база
XLSX отзывов F70, G60, G70	Исходные байты, листы, непустые строки, отзывы по ID и связи со строками
sales_volumes.xlsx	36 целочисленных объёмов по группе моделей, рынку и году; сценарий не указан
XLSX исследований	1 833 средних оценок или долей по показателю, модели, региону и году
Три OptionList PDF	Исходные байты и извлечённый текст 78 пронумерованных страниц

Исходные XLSX/PDF сохраняются в базе как объекты с адресацией по SHA-256. Для таблиц дополнительно хранятся названия листов, непустые строки, номера строк, типы ячеек, форматы чисел и формулы. Числовые показатели привязаны к конкретным ячейкам. Незнакомую структуру можно сохранить как generic с сырыми строками, но для осмысленных показателей потребуется отдельный адаптер.

2. Этап 1: поиск тем и тональность по правилам

Первый этап реализован в feedback_topics.py. Он локальный и воспроизводимый: используются NumPy и openpyxl, без нейросетей, предобученных моделей, внешних API, SciPy и scikit-learn. Результат - F70_topics.json со схемой 1.0. В JSON записаны хеш исходной книги, лист, параметры, правила, отзывы, фрагменты, назначения тем и предупреждения.

1. Текст делится по предложениям, переносам и некоторым противопоставлениям. Длинные части делятся на отрезки не более 65 слов. Сохраняются точные подстроки исходного отзыва и позиции начала/конца. Повторяющиеся после нормализации пробелов фрагменты объединяются только для расчёта; все исходные вхождения остаются.

2. Текст приводится к нижнему регистру, разбивается на слова, очищается от английских стоп-слов; близкие формы объединяются редактируемыми словарными соответствиями. Строятся униграммы и биграммы. В векторы тем попадает только текст отзывов, без метаданных.

3. Остаются термины из минимум 2 уникальных фрагментов и максимум 75% фрагментов; предел словаря - 10 000 признаков. TF = 1 + ln(число повторений); IDF = 1 + ln((1 + число уникальных фрагментов)/(1 + частота термина по фрагментам)). Векторы нормируются по L2.

4. Считается косинусная близость, затем иерархическая кластеризация average linkage методом цепочки ближайших соседей. Порог расстояния по умолчанию - 0.94. Полная матрица близостей требует O(n^2) памяти; --max-memory-mb ограничивает расчёт (по умолчанию 768). Пустые векторы сохраняются как неназначенные фрагменты.

5. Темы называются по наиболее весомым TF-IDF-терминам, сортируются по числу уникальных отзывов и получают ID вида T0001. Внутри темы отзыв считается один раз, даже если подходит несколько его фрагментов. По разным фрагментам один отзыв может попасть в разные темы.

Тональность считается отдельно от кластеризации. В sentiment_rules_en.json находятся редактируемые английские правила слов/фраз, веса, признаки просьбы и окно локального отрицания. Длинные выражения имеют приоритет над перекрывающимися короткими. Метки фрагмента: positive, negative, mixed или undetermined; neutral зарезервирована для будущей явной разметки. Просьба - отдельный признак, не обязательно негатив. Итог для пары «отзыв - тема» объединяет метки её фрагментов. Сработавшие правила и отрицания остаются в JSON.

Результат первого этапа F70	Значение
Словарь; уникальные нормализованные фрагменты	4 111 терминов; 7 388 фрагментов
Все вхождения фрагментов	7 596
Отзывы с темой / полностью без темы	2 115 / 13
Фрагменты без темы	525; сохранены в исходном JSON
Темы менее чем с 3 отзывами	15; помечены, а не удалены

3. Этап 2: точная статистика и AI-пояснения

summarize_topics.py до вычислений проверяет все связи между отзывами, темами и фрагментами. Результат - F70_topics_summary.json со схемой 2.0. Количества, доли, сравнения сегментов, метки тональности и сигналы вычисляются Python-кодом. AI не может изменить эти значения. Общая тональность считает каждый исходный отзыв один раз по всем его фрагментам, включая части вне тем. Темы могут пересекаться, поэтому сумма их численностей не равна размеру корпуса.

Знаменатель доли модели/страны/двигателя в теме - review_count этой темы. Для negative_or_mixed_rate числитель - отрицательные + смешанные отзывы сегмента в теме; знаменатель - все отзывы этого сегмента в теме. topic_prevalence_in_source_segment делит отзывы сегмента в теме на все исходные отзывы этого сегмента. Совместная статистика страны и двигателя берётся из реальных пересечений, а не перемножением отдельных долей. Доли записаны числами от 0 до 1.

Автоматический описательный сигнал по умолчанию требует минимум 10 отзывов в сегменте. Он появляется, если доля negative + mixed не ниже 0.8, либо разница с остальными отзывами среза не меньше 0.2 при достаточном размере второй группы. Это исследовательские флаги, без проверки статистической значимости, поправки на множественные сравнения и причинного вывода.

Для AI-описания выбираются до 16 фрагментов на тему: представлены доступные классы тональности, отмеченные сегменты и характерные формулировки. Это целенаправленная выборка, не случайная выборка для оценки распространённости. OpenAI Responses API получает выбранные цитаты и уже вычисленную статистику и пишет английские названия, краткие описания по тональности, общий обзор и пояснения со ссылками на доказательства. Ответ обязан соответствовать структуре JSON. Проверяются ID фрагментов и сигналов, соответствие тональности, схема и числовые утверждения в прозе; неверные ответы исправляются повторным запросом либо отклоняются. Текст источника считается недоверенными данными. Ключ API берётся из окружения или скрытого ввода и не записывается в отчёт; запрос использует store=false. Вызовы API платные.

В текущем скрипте модель по умолчанию - gpt-5.4, число параллельных работников - 5. Кеш с ключом из модели, инструкции, схемы и данных позволяет продолжать работу. --stats-only считает всю числовую часть без сети; --limit N ограничивает новые описания за один запуск. Возможные статусы: statistics_only, partial, complete. Для F70 сохранён complete: готовы все 460 тем и общий обзор. В результате также остаются определения, настройки, хеш исходного файла, цитаты и ограничения каждой темы.

4. Этап 3: читаемые файлы и каталог для AI

export_topics.py читает готовый JSON второго этапа. Он не делает AI-вызовов и не пересчитывает метки. Для F70 каталог по умолчанию называется F70_topics_summary.readable. Его 465 файлов - это 460 полных JSON тем и пять файлов верхнего уровня: report.html, overview.md, overview.json, topics.jsonl и README.md.

Файл	Для чего нужен
report.html	Автономный отчёт в браузере: поиск, фильтры, сортировка, доли тональностей и стран, цитаты и ограничения
overview.md	Краткий обзор для человека и рейтинги ведущих тем
overview.json	Точные общие значения, настройки, определения, предупреждения и происхождение
topics.jsonl	Компактный каталог: одна тема в строке, ссылка на полный файл
topics/Txxxx.json	Полная запись выбранной темы из второго этапа
README.md	Порядок чтения, знаменатели, предупреждение о пересечениях и подсказки по поиску

Для AI сначала читайте README.md, overview.md и overview.json; затем выбирайте ID по topics.jsonl и загружайте полные JSON только нужных тем. Так не надо помещать весь отчёт в контекст. Каталог F70 занимает 622 557 байт против 7 010 754 байт исходного summary - примерно в 11.3 раза меньше. Компактный каталог не заменяет полные доказательства. Цитаты сохраняются дословно и экранируются при выводе в HTML; подписи интерфейса и AI-описания - английские.

Готовый HTML можно открыть напрямую в обычном браузере. report_template.html - лишь шаблон, не готовый отчёт. Повторный запуск export_topics.py обновляет выбранный каталог. --top ограничивает только рейтинг Markdown, --small-sample меняет только визуальную отметку. Все темы остаются в HTML, JSONL и подробных файлах.

5. Версионируемая SQLite-база и передача данных

Граница хранения описана в data_library.py, library_schema.sql и DATA_LIBRARY.md. База по умолчанию - data_library/library.sqlite, версия схемы - 1. В текущей базе 8 исходных наборов и 1 связанный анализ F70. Каждый запуск анализа указывает на точную версию книги отзывов и хеши обоих исходных JSON; ID темы вроде T0001 уникален лишь внутри запуска. Детерминированные UUID включают набор данных в идентификатор отзыва, а версию и ячейку - в идентификатор показателя.

Таблицы / представления	Назначение
assets, datasets, dataset_versions	Исходные байты, логические наборы и неизменяемые версии
sheets, source_rows	Структура Excel, типизированные строки, форматы ячеек и формулы
reviews, review_rows	Уникальные отзывы и все подтверждающие строки источника
sales_observations, study_observations	Числовые показатели со ссылкой на исходную ячейку
document_pages, import_issues	Текст страниц, признаки OCR и замечания к интерпретации
analysis_runs, analysis_topics, topic_reviews, fragments	Темы и цитаты, привязанные к версии исходных данных
current_versions, current_reviews, current_sales, current_studies	Последняя успешная версия каждого набора

Импортёр проверяет повторяющиеся ID, противоречия, конечность чисел, ссылки на источники и внешние ключи. Команда check запускает проверку целостности SQLite, внешних ключей и SHA-256 каждого сохранённого файла. ingest-all обрабатывает каждый входной файл отдельной транзакцией и прикрепляет подходящие пары *_topics.json / *_topics_summary.json. status показывает F70 как Analysis ready, а G60/G70 - как Awaiting analysis. Новая версия книги остаётся в ожидании, пока к её точным байтам не будет прикреплён анализ.

Экспорт в пустую папку создаёт согласованную копию SQLite, таблицы JSONL, исходные файлы, schema.sql, schema.json, читаемый STATUS.md и manifest.json с хешами SHA-256 и размерами. В архив включены все исторические версии; представления current_* показывают актуальные. Первый переносимый архив - data_library/exports/initial.zip. Python-проект может открыть library.sqlite напрямую. В другую СУБД данные можно загрузить из JSONL с теми же ограничениями и составными связями dataset/version/run.

6. Как продолжать работу команде

Команды выполняются из feedback_topics_package после установки зависимостей Python 3.10+ из requirements.txt. Для каждой новой таблицы отзывов используйте уникальный префикс файлов. Держите книгу и два созданных JSON рядом, чтобы ingest-all нашёл соответствующую пару.

```
python -m pip install -r requirements.txt
python feedback_topics.py "G60_feedback_hackathon.xlsx" --output G60_topics.json
python summarize_topics.py G60_topics.json --output G60_topics_summary.json
python export_topics.py G60_topics_summary.json
python data_library.py ingest-all .
python data_library.py status
python data_library.py check
python data_library.py export --output data_library/exports/next-release
```

Чтобы посмотреть только числовой результат без оплаты API, используйте --stats-only вместо обычного вызова summarize. Для продолжения частичного AI-анализа сохраняйте прежние выходной файл, модель и кеш. Не запускайте два экземпляра summarizer с одним выходным файлом. Обновлённую полную книгу можно загрузить командой python data_library.py ingest "updated.xlsx" --dataset g60_feedback_hackathon. Анализ старых байтов не делает новую версию готовой. После изменений экспортируйте в новую пустую папку: прежний архив и HTML-отчёт - снимки состояния.

Ограничения интерпретации и интеграции

Кластеры - лексически похожие кандидаты тем, которые должен просмотреть продакт-менеджер; порог 0.94 - выбранная граница расстояния, а не вероятность или доказательство существования ровно 460 тем. Точность английских правил тональности на независимой ручной разметке не измерялась. Сарказм, далёкие отрицания, смешанные аспекты и другие языки могут давать ошибки. Редкие слова после фильтра min_df могут остаться без темы. Косинусная близость и веса правил - не вероятности уверенности.

Объединённые группы моделей, например G60_G68, в продажах не разделяются; scenario=unspecified, потому что в таблице нет однозначной маркировки факта и прогноза. У средних оценок исследования неизвестны границы шкалы и число респондентов; доли US - дроби, поэтому Sample total = 1 означает 100%, а не одного человека. Несопоставимые оценки нельзя усреднять. PDF индексируются по тексту страниц: цены, коды опций и отношения в таблицах не структурированы и не проверены. Страницы без извлекаемого текста помечены needs_ocr. Сохранённые значения формул Excel могут устареть.

Цитаты клиентов и поля источников сохраняются на исходном языке. Текст интерфейса, созданные AI-описания и сообщения кода - английские. Исходные данные, секреты API, база и экспортные пакеты исключены из Git. Передавайте архив через согласованное командное хранилище и проверяйте хеши manifest.json после переноса.

Карта файлов проекта

Реализация: feedback_topics.py, sentiment_rules_en.json, summarize_topics.py, export_topics.py, report_template.html, data_library.py и library_schema.sql. Руководства: README.md и DATA_LIBRARY.md в feedback_topics_package. Проверки: test_feedback_topics.py, test_summarize_topics.py, test_export_topics.py, test_data_library.py и test_report_ui.js. Текущие значения сверены с итоговым F70 summary и состоянием SQLite; все 54 Python-теста проходят. UI smoke test проверяет логику через заглушку документа, а не внешний вид в браузере.